# Détection Probabiliste de Manipulation de Marchés

## Soutenance Intermédiaire 2 - Projet de Recherche

Adonis Jamal  Jean Martini
Encadrant : Damien Challet

CentraleSupélec – Laboratoire MICS

16 février 2026

# Sommaire

1. Introduction
   - Rappel du Contexte
   - Objectifs et Avancement
2. Méthodologie
   - Approche Globale
   - Entraînement Robuste
   - Définition du Seuil et Décision

# Le défi de la détection de spoofing

## Le Mécanisme

- **Action :** Placer des ordres massifs non-bona fide loin du prix.
- **But :** Créer une illusion de pression pour manipuler les algorithmes.
- **Signal :** Dépendance forte à la distance au mid-price et au flux d'ordres [Tao+20].

## Verrous Scientifiques

1. **Absence de Vérité Terrain :** Pas de labels "Manipulé / Non Manipulé".
2. **Non-stationnarité :** Le marché change de régime (volatilité, liquidité) en permanence.
3. **Contamination :** Le jeu d'entraînement contient déjà des manipulations invisibles.

# Trajectoire du projet

**Objectif final :** Une meilleure caractérisation de la "spoofability" des marchés, avec une comparaison entre actions et crypto.

1. **Phase 1 : Modélisation (Oct - Déc)**
   - Prise en main et exploration de l'état de l'art et des features.
   - Construction des features (Hawkes Process [FC25], LOB shape).
   - Implémentation de modèles (PNN, Transformer+OCSVM [PCM24]).
2. **Phase 2 : Détection Robuste (Jan - Fév)**
   - Entraînement séquentiel pour gérer le drift.
   - Gestion de la contamination (PRAE).
   - Gestion du seuil de décision (EVT/DSPOT, FDR).
3. **Phase 3 : Interprétabilité & Analyse (Mars - Avr)**
   - Entraînement final avec Ruche.
   - Interprétabilité (Integrated Gradients, Occlusion).
   - Tests sur les données crypto et comparaison avec les actions.

# Architecture du Pipeline de Détection

On couple un **générateur de score robuste** avec un **décideur adaptatif**.

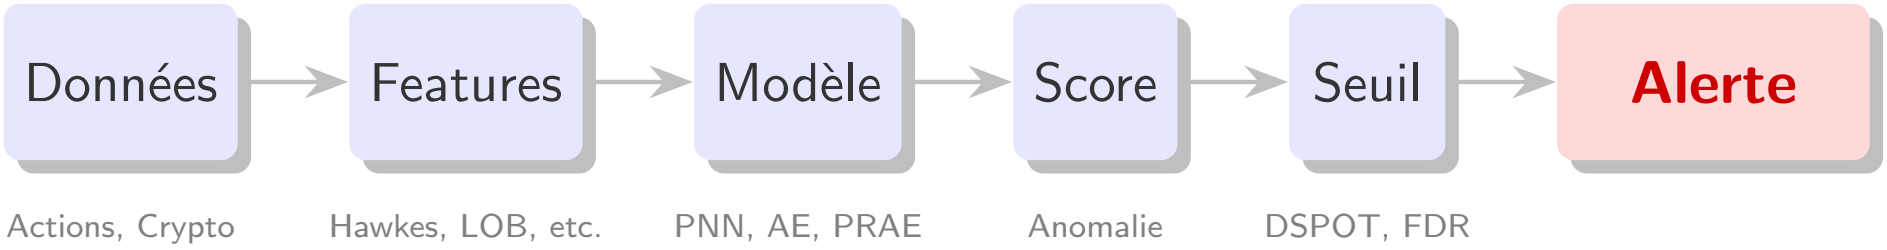


- **Problème 1 (Apprentissage) :** Le jeu de données d'entraînement contient déjà des manipulations. Un Auto-Encodeur standard apprendrait à les reconstruire.
- **Solution 1 : PRAE**, Probabilistic Robust Auto-Encoder [LAK22].
- **Problème 2 (Inférence) :** La distribution des erreurs de reconstruction change au cours du temps.
- **Solution 2 : DSPOT**, Drift Streaming Peaks-Over-Threshold [Sif+17].

# Entraînement robuste : PRAE

**Contexte :** L'historique contient des épisodes manipulés non étiquetés.
**Idée :** Apprendre simultanément les paramètres du réseau $\theta$ et le "degré de normalité" $z_i$ de chaque échantillon $x_i$.

## Principe [LAK22]

On apprend une variable latente $z_i \in [0, 1]$ (inlierness) pour chaque échantillon $x_i$.

- $z_i \approx 1$ : **Inlier** (Donnée saine). Le modèle doit minimiser l'erreur de reconstruction.
- $z_i \approx 0$ : **Outlier** (Manipulation/Bruit). Le modèle doit ignorer cette donnée.

Cela permet de "nettoyer" le dataset de manière endogène pendant l'entraînement, sans supervision externe.

# PRAE : Formulation Mathématique

On peut décrire la fonction de coût par rapport au poids $\psi, \rho$ du réseau et des variables latentes $z_i$ :

$$L_{p_n}(\psi, \rho, \mu) = \mathbb{E}\left(\sum_i z[i] \, \|x_i - \hat{x}_i\|_2^2 - \lambda \|z\|_n\right),$$

avec $z[i] = \max\left(0, \min\left(1, \mu[i] + \epsilon[i]\right)\right), \quad \epsilon[i] \sim \mathcal{N}(0, \sigma^2)$.

- **Rôle de $\lambda$ :** Contrôle la quantité de données rejetées.
  - Si l'erreur $\|x_i - \hat{x}_i\|^2 > \lambda$, il est optimal de mettre $z_i = 0$.
  - $\lambda$ agit comme un seuil implicite de robustesse.

Le vecteur $\mu$ sert de score d'anomalie pour chaque échantillon : plus $\mu_i$ est petit, plus $x_i$ est considéré comme un outlier.

# DSPOT : Théorie des Valeurs Extrêmes (EVT)

Une fois le modèle entraîné, nous obtenons un flux de scores d'anomalie $e_t$. Il faut définir un seuil de décision pour déclencher une alerte.

## Hypothèse EVT (Pickands-Balkema-De Haan)

Pour une large classe de distributions, la distribution des excès $y = e_t - u$ au-dessus d'un seuil élevé $u$ converge vers une Loi de Pareto Généralisée (GPD) :

$$G_{\gamma,\sigma}(y) = 1 - \left(1 + \frac{\gamma y}{\sigma}\right)^{-1/\gamma}$$

Cela nous permet d'estimer la probabilité d'événements rares ("Queue de distribution") sans connaître la distribution complète des données (souvent inconnue et complexe).

# DSPOT : Algorithme de seuillage dynamique

## Calcul du seuil d'alerte $z_q$

Pour un risque cible $q$ (ex: $10^{-4}$), le seuil $z_q(t)$ est donné par l'inversion de la GPD :

$$z_q(t) = u + \frac{\sigma_t}{\gamma_t}\left[\left(\frac{qN_w}{N_u}\right)^{-\gamma_t} - 1\right]$$

- $\sigma_t, \gamma_t$ : Paramètres d'échelle et de forme (estimés par MLE sur les pics récents).
- $N_w$ : Taille de la fenêtre glissante.
- $N_u$ : Nombre de pics dans la fenêtre.

DSPOT met à jour les paramètres sur une fenêtre glissante pour s'adapter au changement de régime $\Rightarrow$ Si le marché devient très volatil, $\sigma_t$ augmente, donc le seuil $z_q(t)$ augmente automatiquement.

Merci pour votre attention

# Bibliographie I

[Sif+17] Alban Siffer et al. "Anomaly Detection in Streams with Extreme Value Theory". In: *KDD 2017 - Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Halifax, Canada, Aug. 2017. DOI: 10.1145/3097983.3098144. URL: https://hal.science/hal-01640325.

[STY17] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. *Axiomatic Attribution for Deep Networks*. 2017. arXiv: 1703.01365 [cs.LG]. URL: https://arxiv.org/abs/1703.01365.

[Tao+20] Xuan Tao et al. *On Detecting Spoofing Strategies in High Frequency Trading*. 2020. arXiv: 2009.14818 [q-fin.TR]. URL: https://arxiv.org/abs/2009.14818.

# Bibliographie II

[LAK22] Ofir Lindenbaum, Yariv Aizenbud, and Yuval Kluger. *Probabilistic Robust Autoencoders for Outlier Detection*. 2022. arXiv: 2110.00494 [cs.LG]. URL: https://arxiv.org/abs/2110.00494.

[PCM24] Cédric Poutré, Didier Chételat, and Manuel Morales. "Deep Unsupervised Anomaly Detection in High-Frequency Markets". In: *The Journal of Finance and Data Science* 10 (Apr. 2024), p. 100129. DOI: 10.1016/j.jfds.2024.100129.

[FC25] Timothée Fabre and Damien Challet. *Learning the Spoofability of Limit Order Books With Interpretable Probabilistic Neural Networks*. 2025. arXiv: 2504.15908 [q-fin.TR]. URL: https://arxiv.org/abs/2504.15908.

# Les marchés et le Carnet d'Ordres

- **Limit Order Book (LOB) :** Répertoire central des intentions d'achat (Bid) et de vente (Ask).
- **Dynamique :** Le prix médian (*mid-price*) réagit à l'état instantané et au flux d'ordres passé (Order Flow).
- **Données :**
  - Données Haute Fréquence (Level 2 / Market-by-order).
  - Nécessité de traiter des millions d'événements par jour.

**Problématique**

La microstructure du marché peut être exploitée pour induire les autres participants en erreur.

# Le spoofing : une manipulation structurelle

- **Définition :** Placer des ordres non-bona fide (sans intention d'exécution) pour créer une fausse impression de liquidité ou de pression directionnelle.
- **Tactiques courantes :**
  - *Layering :* Empilement d'ordres à différents niveaux de prix.
  - *Vacuuming :* Création de vides de liquidité pour provoquer des mouvements brusques.
- **Mécanisme :**
  1. Placer un gros ordre d'achat (Fake) loin du prix.
  2. Attendre que le prix monte (réaction des algos).
  3. Vendre réellement (Bona fide) à un prix plus élevé.
  4. Annuler l'ordre d'achat initial.

# Hypothèses de travail

## Hypothèses Microstructurelles

- La distance de placement des ordres limites joue un rôle critique dans la formation des prix (contrairement aux modèles basés uniquement sur le volume au best bid/ask) [Tao+20].
- Un agent manipulateur agit rationnellement pour minimiser son coût d'exécution espéré.

## Hypothèse Comparative

En l'absence de régulation stricte, les carnets d'ordres de crypto-monnaies (CEX) présentent :

- Une fréquence de spoofing plus élevée.
- Une sensibilité (impact prix) plus forte aux ordres de spoofing que les marchés actions traditionnels.

# Entraînement séquentiel

## Pourquoi séquentiel

Les distributions de features et de scores dérivent (liquidité/volatilité/régimes). Un entraînement "one-shot" généralise mal.

## Stratégie explorée

1. **Entraînement** sur une période de 1 heure, divisée en blocs d'entraînement et de validation (3 à 6 blocs).
2. **Fine-tuning** jour après jour avec early stopping.
3. **Tests** sur un nouveau jour avec distinction entre matin et restant de la journée.

# Integrated Gradients pour l'Interprétabilité

**Objectif :** attribuer la contribution des features à un score (log-vraisemblance, erreur, etc.) pour les modèles **dérivables**.

## Principe

On compare une entrée $x$ à une baseline $x'$ et on intègre les gradients le long du chemin $x' \to x$ :

$$\mathrm{IG}_i(x) = (x_i - x_i') \int_0^1 \frac{\partial f\big(x' + \alpha(x - x')\big)}{\partial x_i} \, d\alpha$$

# Occlusion Sensitivity pour l'Interprétabilité

**Objectif :** interpréter des modèles **non-dérivables** (ex : One-Class SVM) ou obtenir une explication modèle-agnostique.

## Principe

On masque (occlusion) un sous-ensemble de variables (ou un groupe : échelle de temps, distance, côté bid/ask) et on observe la variation du score :

$$\Delta s = s(x) - s\big(\mathrm{mask}(x, \mathcal{G})\big)$$

Une grande chute du score signifie que le groupe $\mathcal{G}$ est important.